

Sesión 2

de filas a preguntas

group_by(), summarise(), joins, pivots y ggplot2

Asociación Vasca de Sociología y
Ciencia Política · Bilbao · 27 mayo 2026



Centro de Investigación en Sociología y Ciencia Política



Universidad
del País Vasco


Euskal Herriko
Unibertsitatea

ikerbasque

Basque Foundation for Science

Ayer construimos una **canalización** de datos

No memorizamos funciones: encadenamos pasos revisables



Idea clave cada paso deja una huella visible: se puede revisar, corregir y reutilizar.

La reproducibilidad no es una obligación abstracta - es un favor a ti mismo en el futuro.

Recordatorio: el proyecto es la casa

Si el código funciona solo en tu ordenador, es una limitación

```
AVSP2026R/  
  data/  
    raw/  
    clean/  
  R/  
  fig/  
  output/
```

Evitar

```
read_csv("/home/tim/Descargas/pobmun.csv")
```

Preferir

```
read_csv("data/clean/pobmun.csv")
```

Transportable = Que puedes mover la carpeta a otro sitio, pero sigue funcionando.

Cuatro verbos que ya conocemos

Una función por una idea

filter()

quedarse con filas

```
poblacion |>  
  filter(prov_cod == "48")
```

select()

quedarse con columnas

```
pob_total_mun |>  
  select(municipio, pob)
```

mutate()

crear o modificar
columnas

```
mutate(pct_65_mas =  
  pob_65_mas / pob * 100)
```

left_join()

añadir columnas desde
otra tabla

```
left_join(pob_65_mas,  
  by = "municipio_cod_full")
```

filter(): elegir observaciones

La tabla mantiene las mismas columnas, pero con menos filas

```
poblacion |>
  filter(genero == "Total",
         edad_etiqueta == "Total",
         prov_cod == "48")
```

Contiene una evaluación lógica; las comas se tratan como “y”

```
poblacion |>
  filter(genero == "Total" &
         edad_etiqueta == "Total" &
         prov_cod == "48")
```

select(): elegir variables

La tabla mantiene las mismas filas, pero con menos columnas

```
pob_total_mun |>  
  select(prov,  
         comarca,  
         municipio,  
         pob)
```

También renombra y reordena

```
select(provincia = prov,  
       poblacion = pob)
```

mutate(): crear variables

`case_when()` sirve para recodificar con reglas claras

```
pob_total_mun |>
  mutate(
    tamano_mun = case_when(
      pob < 1000 ~ "menos de 1.000",
      pob < 5000 ~ "1.000-4.999",
      pob < 20000 ~ "5.000-19.999",
      TRUE ~ "20.000 o más"
    )
  )
```

left_join(): añadir información

Una tabla principal + una tabla auxiliar + una clave común

```
resumen_prov |>  
  left_join(pib_prov, by = "prov_cod")
```

tabla izquierda: se conserva
tabla derecha: aporta columnas
by = el clavo de la union

Regla práctica

Juntar por códigos cuando existan; usar nombres solo cuando no haya alternativa o si estás segurísimo de que los nombres sean escritos de forma idéntica.

Hoy subimos un piso, no diez

El objetivo sigue siendo confianza, no velocidad.

1

Recodificar

`case_when()`

2

Resumir

`group_by() + summarise()`

3

Cruzar datos

`left_join()`, `(right_`, `full_`, `inner_`, `anti_`, `cross_`)

4

Pivotar

`pivot_wider()`, `pivot_longer()`

5

Graficar

`ggplot() + geom_*()`

group_by() + summarise(): agregación

De municipios a comarcas o provincias

```
pob_total_mun |>
  group_by(prov, comarca) |>
  summarise(
    poblacion_total = sum(pob),
    municipios = n(),
    .groups = "drop"
  )
```

Idea

agrupamos filas, calculamos una o varias medidas, y obtenemos una tabla nueva.

Pivotar: cambiar la forma de la tabla

Largo no es mejor siempre; ancho tampoco. Depende de la tarea

```
poblacion |>
  filter(genero == "Total", !is.na(edad)) |>
  group_by(municipio_cod_full) |>
  mutate(pct = pob / sum(pob) * 100) |>
  pivot_wider(names_from = edad,
              values_from = pct)
```

Para comparar columnas

ejemplo: % 0-19 frente a
% 65+ por municipio.

Ejercicio: volver a largo
con `pivot_longer()`.

ggplot2: capas, no magia

datos + aes() + geometría + etiquetas

```
resumen_comarca |>
  arrange(desc(pct_65_mas)) |>
  slice_head(n = 10) |>
  ggplot(aes(x = reorder(comarca, pct_65_mas),
               y = pct_65_mas)) +
  geom_col() +
  coord_flip() +
  labs(title = "Comarcas con mayor % 65+",
       x = NULL, y = "% 65+")
```

datos

mapeo estético


capa geométrica

detalles

Ejercicio: cambiar de población total a pct_65_mas.

Ruta de la sesión

Primero recuperamos, luego extendemos



Al final de hoy: una tabla resumen, un cruce con INE, una tabla pivotada y gráficos.